School of Economics and Management, Beihang University

现代程序设计技术

赵吉昌

本周内容

- 面向对象编程
  - 进程与线程
  - 多进程

并行与并发

- 并行与并发
  - 并行（parallel）
    - 在同一时刻，有多条指令在多个处理器上同时执行
  - 并发（concurrency）
    - 在同一时刻，只能有一条指令执行，但多个指令被快速轮换执行，使得在宏观上表现多个指令同时执行的效果

进程和线程

- 进程和线程
  - 进程（process）
    - 操作系统分配资源的基本单位
  - 线程（thread）
    - CPU调度和分派的基本单位
  - 应用程序至少有一个进程
  - 一个进程至少有一个线程
  - 同一进程的多个线程可以并发执行
  - 进程在执行过程中拥有独立的内存单元，而线程共享内存
  - 多进程编程需要考虑进程间的通信 (IPC)
  - 进程切换时，耗费资源较大

进程和线程的比较

对比维度	多进程	多线程	总结
数据共享、同步	数据共享复杂，需要用IPC； 数据是分开的，同步简单	共享进程数据，数据共享简单，但导致同步复杂	各有优势
内存、CPU	占用内存多，切换复杂，CPU利用率低	占用内存少，切换简单，CPU利用率高	线程占优
创建销毁、切换	创建销毁、切换复杂，速度慢	创建销毁、切换简单，速度很快	线程占优
编程、调试	编程简单，调试简单	编程复杂，调试复杂	进程占优
可靠性	进程间不会互相影响	一个线程出错将导致整个进程中止	进程占优
分布式	适用于多核、多机分布式	适用于多核分布式	进程占优

多进程

- 进程（process）
  - 进程号
    - os.getpid()
  - 孤儿进程
    - 子进程在父进程退出后仍在运行，会被init进程接管，init以父进程的身份处理子进程运行完毕后遗留的状态信息
  - 僵尸进程
    - 父进程创建子进程后，如果子进程退出，但父进程并没有调用wait或waitoid获取子进程的状态信息，那么子进程的进程描述符将一直保存于系统，对应的子进程称为僵尸进程
    - 僵尸进程无法通过kill命令来清除

多进程

- multiprocessing模块
  - 开启子进程并在其中执行定制任务
  - 提供Process、Queue、Pipe、Lock等关键组件
  - 支持进程间的通信与数据共享
  - 执行不同形式的同步
  - 处理僵尸进程

多进程

- Process
  - 创建进程类
    - Process([group [, target [, name [, args [, kwargs]]]]])
  - 实例对象表示一个子进程（尚未启动）
  - 使用关键字的方式来指定参数
    - group参数未使用，值始终为None
    - target表示调用对象，即子进程要执行的任务
    - args指定传给target调用对象的位置参数，元组形式，仅有一个参数时要有逗号
    - kwargs表示调用对象的字典参数
    - name为子进程的名称
  - 在Windows中Process()必须放到if __name__ == '__main__'中

多进程

- Process
  - p.start()
    - 启动进程，并调用该子进程中的p.run()
  - p.run()
    - 进程启动时运行的方法，会调用target，自定义类定要实现该方法
  - p.terminate()
    - 强制终止进程p，但不进行任何清理操作
    - 如果p创建了子进程，该子进程将成为僵尸进程
    - p创建的锁也将不会释放，可能导致死锁
    - 一般不建议使用

多进程

- Process
  - p.is_alive()
    - 如果p仍然运行，返回True
  - p.join([timeout])
    - 主进程等待p终止（主进程处于等状态，而p处于运行状态）
    - timeout是可选的超时时间
    - 只能join住start开启的进程，而不能join住run开启的进程

多进程

- Process
  - p.daemon
    - 默认值为False
    - 可以设置为True，但必须在p.start()之前设置，成为后台运行的守护进程，当p的父进程终止时，p也随之终止，且p不能创建新的子进程
  - p.name
    - 进程的名称
  - p.pid
    - 进程的pid
  - p.exitcode
  - 进程在运行时为None
    - 如果为-N，表示被信号N结束
  - p.authkey
    - 进程的身份验证键

多进程

- 进程实现Demo
  - 通过Process实现
  - 通过继承Process实现
  - Demo:mp_error.py (on windows)
  - Demo: mp.py
  - 关于join的使用
    - 先在主进程中启动所有子进程
    - 然后在主进程中对所有子进程进行join
      - 子进程都启动后再join，启动后马上join会变成“串行”
      - 虽然join仍会等等p1运行结束，但其他子进程如p2，p3等仍在运行，等p1运行结束后，循环继续，p2,p3等可能也运行结束了，，会迅速完成join的检验
      - join花费的总时间仍然是耗费时间最长的子进程的运行时间

多进程

- 同步
  - 按预定的顺序先后执行
  - 调用后需要等到返回结果
  - 同步是保证多进程安全访问竞争资源的一种手段
- 异步
  - 与同步处理相对
  - 异步处理不用阻塞当前进程来等待处理完成，而是允许后续操作，并回调通知

临界区

- 临界资源
  - 一次仅允许一个进（线）程使用的资源称为临界资源
- 临界区
  - Critical Section
  - 存取临界资源的代码片段
  - 多进程要求进入空闲的临界区时，一次仅允许一个进（线）程进入
  - 如已有进（线）程进入临界区，则其它试图进入临界区的进（线）程需要等待
  - 进入临界区的进（线）程要在有限时间内退出

互斥量

- 互斥量
  - mutex
  - 是一个仅处于两态之一的变量
    - 解锁
    - 加锁

多进程

- 进程的同步
  - 实现机制
    - 互斥锁(Lock)
    - 信号量(Semaphore)
    - 事件(Event)
    - 条件(Condition)[下周结合线程举例]
  - Demo: mp1.py mps.py mpe.py
  - 特征
    - 可以用文件共享数据
      - 效率低
    - 加锁可以保证多个进程修改同一块数据时，同一时间只能有一个进程可以进行修改，即串行修改
      - 但需要自行加锁处理

多进程

- 基于消息的IPC通信机制
  - IPC
    - inter-process communication
  - 队列和管道

多进程

- 队列
  - Queue([maxsize])
  - q.put()
    - 插入数据到队列，参数blocked默认为True
    - 可能抛出Queue.Full异常
  - q.get()
    - 从队列读取并删除一个元素
    - 可能抛出Queue.Empty异常
  - 不可靠方法
    - q.empty()
    - q.full()
    - q.qsize()

多进程

- 生产者-消费者模型
  - Demo: mpq.py
  - 如何往队列中发送结束信号
    - 生产者进程发送
    - 消费者进程进行判断
    - 或主进程发送（注意要为每个消费者进程发送一个）

多进程

- JoinableQueue([maxsize])
  - 允许数据的消费者通知生成者数据已经被成功处理
    - 通过共享信号和条件变量来实现通知
  - maxsize
    - 队列中允许最大数据项数，省略则无大小限制
  - q.task_done()
    - 消费者使用此方法发出信号，表示q.get()的返回数据已经被处理，但如果调用此方法的次数大于从队列中删除数据的数量，将引发ValueError异常
  - q.join()
    - 生产者调用此方法进行阻塞，直到队列中所有的项目均被处理，阻塞将持续到队列中的每个数据均调用q.task_done()方法为止
  - Demo: mpjq.py pq2.py

多进程

- 管道（pipes)
  - FIFOS (named pipes) (Demo: 终端命令)
    - using regular files to communicate
    - the kernel takes care of synchronizing reads and writes
    - data is never actually written to disk (instead it is stored in buffers in memory)
    - the overhead of disk I/O is avoided.
    - A FIFO is part of the file system
  - Pipes
    - like FIFOs without the name
    - a read end and a write end
    - a read from a pipe ***only gives end-of-file if all file descriptors*** for the write end of the pipe have been closed
      - after a fork, whichever process is intending to do the reading (and thus not the writing) had best close the write end of the pipe
  - Processes communicating via pipes must be running on the same host
    - 补充：跨机需要通过socket

多进程

- 管道
  - 一般用于两个进程间通信
  - 但也可以用于多个进程
  - Demo: piped.c pipes.c

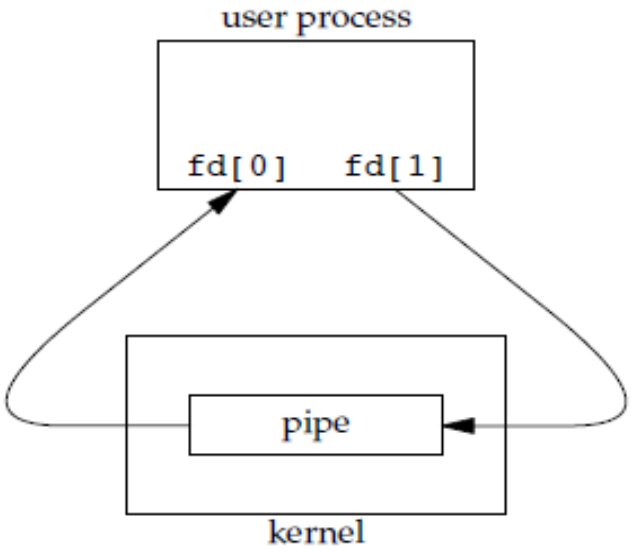

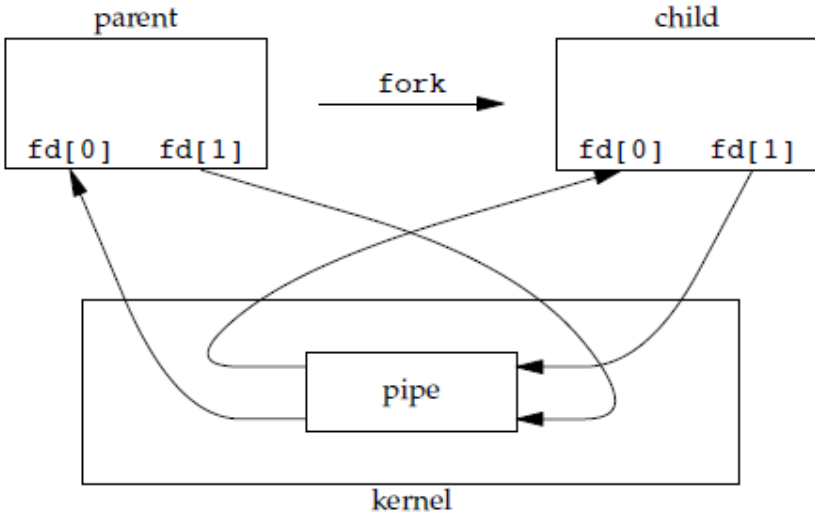

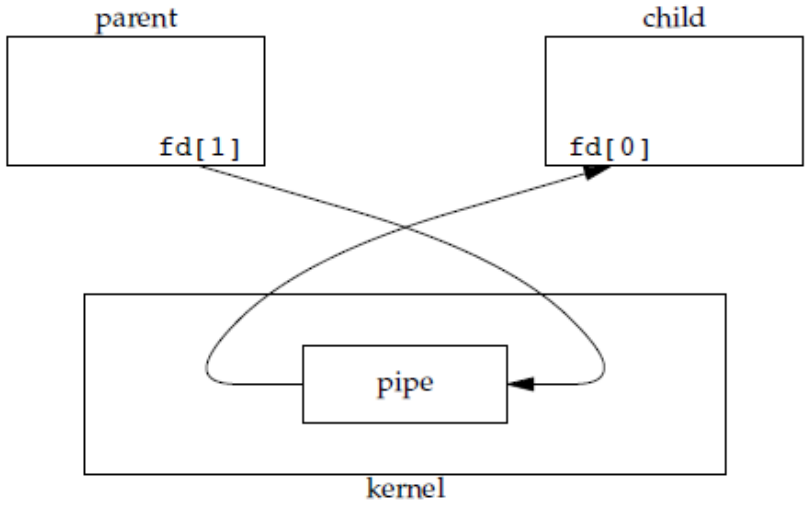

多进程

- 管道
  - Pipe([duplex])
  - 在进程之间创建一条管道，并返回元组（conn1,conn2），其中conn1，conn2表示管道两端的连接对象
  - conn1：读，接收消息
  - conn2：写，发送消息
  - 必须在产生Process对象之前产生管道
  - dumplex
    - 默认全双工，如果将duplex置为False，对于一个进程，只能通过conn1接收或者只能通过conn2发送

多进程

- 管道
  - conn1.recv()
    - 接收conn2.send(obj)发送的对象，如果没有消息可接收，recv方法会一直阻塞
    - 如果连接的另外一端（所有）已经关闭，那么recv方法会抛出EOFError
  - conn2.send(obj)
    - 通过连接发送对象，obj是与序列化兼容的任意对象
  - conn1.close()
    - 关闭连接
  - Demo: mpp.py

本周作业

- MapReduce是利用多进程并行处理文件数据的典型场景。作为一种编程模型，其甚至被称为Google的”三驾马车“之一(尽管目前由于内存计算等的普及已经被逐渐淘汰)。在编程模型中，Map进行任务处理，Reduce进行结果归约。本周作业要求利用Python多进程实现MapReduce模型下的文档库（搜狐新闻数据(SogouCS)（下载地址：https://www.sogou.com/labs/resource/cs.php），注意仅使用页面内容，即新闻正文）词频统计功能。具体地：
  - 1. Map进程读取文档并进行词频统计，返回该文本的词频统计结果。
  - 2. Reduce进程收集所有Map进程提供的文档词频统计，更新总的文档库词频，并在所有map完成后保存总的词频到文件。
  - 3. 主进程可提前读入所有的文档的路径列表，供多个Map进程竞争获取文档路径；或由主进程根据Map进程的数目进行分发；或者单独实现一个分发进程，与多个Map进程通信。
  - 4. 记录程序运行时间，比较不同Map进程数量对运行时间的影响，可以做出运行时间-进程数目的曲线并进行简要分析。